



Metodos de Optimizacion NO lineal

Integrantes

Juan Pablo Oriana - 60621

Tomas Cerdeira - 60051

Santiago Garcia Montagner - 60352



Objetivos del trabajo

- Analizar 3 metodos de optimizacion NO lineal que minimicen el error
 - Gradiente descendiente
 - Gradiente conjugado
 - ADAM
- Datos:

$$W = \begin{pmatrix} W_0 \\ W_1 \\ W_2 \end{pmatrix} \quad w = \begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \end{pmatrix} \quad w_0 = (w_{01}, w_{02})$$

Se busca **minimizar el error** e informar los **argumentos y algoritmos óptimos** que más se ajusten a los reactivos iniciales dados como “ciertos”.

Función F

- Dados:

$$\underline{g(x)} = \frac{e^x}{1+e^x} \quad \text{Función logística}$$

ξ^k

Valores de entrada, con $k = 1, 2, 3$

ζ

Valores de salida

$$\Rightarrow \underline{F(W, w, w_0, \xi)} = \underline{g\left(\sum_{j=1}^2 W_j g\left(\sum_{k=1}^3 w_{jk} \xi_k - w_{j0}\right) - W_0\right)}$$

Donde el error resulta $E(W, w, w_0) = \sum_{\mu=1}^3 (\zeta^\mu - \underline{F(W, w, \xi^\mu)})^2$



Valores de entrada ξ

$$\xi^1 = \begin{pmatrix} 4,4793 \\ -4,0765 \\ -4,0765 \end{pmatrix}$$

$$\zeta^1 = 0$$

$$\xi^2 = \begin{pmatrix} -4,1793 \\ -4,9218 \\ 1,7664 \end{pmatrix}$$

$$\zeta^2 = 1$$

$$\xi^3 = \begin{pmatrix} -3,9429 \\ -0,7689 \\ 4,8830 \end{pmatrix}$$

$$\zeta^3 = 1$$



Objetivo de los métodos


- Determinar el **valor de las variables independientes**, sujetas éstas en muchos casos a restricciones, **que maximizan o minimizan el valor de una función**
- Se realiza mediante la **penalización de la función objetivo**
 - **nueva función objetivo** que contiene a la original y a un término que cuando las restricciones estén próximas a no cumplirse incrementa el valor
 - es un **problema de minimización**





Metodo de Optimizacion NO lineal *gradiente descendente*

Gradiente Descendente


- Definiendo un **número de iteraciones** y una **tasa de aprendizaje**, se busca llegar al **mínimo de la función**.
 - Se escoge un valor de forma aleatoria de w
 - En cada iteración se actualiza el $w = w - \alpha \cdot \text{gradiente}$





Ejemplo con curvas de nivel



Sección de F sobre la
gradiente



Ejemplo con curvas de nivel



Avanza en zig-zag





Gradiente Descendente Estocástico

- Método de **gradiente descendiente es costoso** ya que utiliza TODA la muestra de entrenamiento para el cálculo de dirección de decrecimiento.
- Surge, gradiente descendiente estocastico , que en cada iteracion toma una muestra de la población para el cálculo de la dirección

$$\sum_{\mu=1}^k \nabla_w E(\xi^\mu, \mathbf{w}^t), \quad k \ll p.$$

- Los autores del método demuestran que este método converge, pero puede tardar más que el método determinístico



Metodo de Optimizacion NO lineal *gradiente conjugada*



Algunas definiciones

Definición 3.5.1. Se dice que $\{\vec{d}_k\}_{k=1}^n$ son vectores mutuamente conjugados respecto a una matriz G simétrica y positiva definida si

$$\vec{d}_k^T G \vec{d}_j = 0 \quad j \neq k. \quad (3.13)$$


e.j.

$$(1, 0) \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} (1/2, 1) = (2 \quad -1) (1/2, 1) = 0$$

OBS: En este caso, la matriz G vendría a ser H , la matriz Hessiana de f

Gradiente Conjugado

- Encontrando los dos **vectores conjugados**, encontramos una solución al problema en **menos pasos** que el **gradiente descendiente**.
 - Se mueve por **vectores ortogonales** que pasan por el x que minimiza a F



Referencias

Youtube - ["Conjugated Gradient Method"](#)

Patricia Saavedra Barrera - ["Introducción a la optimización no lineal"](#) (desde pág 68)



Metodo de Optimizacion NO lineal *ADAM (Adaptive Moment Estimation)*



ADAM (Adaptive Moment Estimation)

- Adapta la tasa de aprendizaje en cada paso
- La actualización del vector w se realiza coordenada a coordenada
- El algoritmo requiere:
 - α Tasa de aprendizaje
 - β_1 y β_2 tasas de decaimiento. β_1 y $\beta_2 \in [0,1)$
 - f función objetivo estocástica
 - $m_0 = 0$. Donde m_0 es el primer vector de momentos
 - $v_0 = 0$. Donde v_0 es el segundo vector de momentos
 - w_0 parámetro inicial



Algoritmo

while w_t not converge do

$t := t + 1$

$$g_t = \nabla f(w_{t-1})$$

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

→ Actualiza la media móvil exponencial del gradiente


$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

→ Actualiza la media móvil exponencial del gradiente al cuadrado

$$w_t = w_{t-1} - \alpha \frac{m_t}{\sqrt{v_t + \epsilon}}$$



Demo



**Gracias por su
atencion.**

